

DAS Tabanlı Çit-İhlali Sınıflandırması

Staj Sonu Raporu

Inosens • 2026-09-04

Bu rapor, staj boyunca yürütülen çalışmanın özetidir: ne yapıldı, nereye kadar gelindi, ne eksik kaldı ve projeye devam edecekler için hangi adımlar öneriliyor. Ayrıntılı ölçüm kayıtları depoda DURUM.md, GERCEK_VERI_EGITIM_SONUCLARI.md ve GERCEK_VERI_FAZO_RAPORU.md dosyalarında tutulmaktadır.

1. Problem ve kapsam

DAS (Φ -OTDR) teknolojisiyle fiber optik kablo, kilometrelerce uzunlukta sürekli bir titreşim sensörüne dönüşmektedir. Bu projenin görevi, tel örgü çitlerdeki ihlal olaylarını sınıflandıran bir derin öğrenme modeli geliştirmektir. Üç sınıf ele alındı: **cutting** (kesme), **climbing** (tırmanma) ve **noise** (gürültü). Mimari, You ve ark. (2025), *DAS-Based Perimeter Intrusion Detection Using 2D-CNN With SKAttention Mechanism*, IEEE Sensors Journal 25(22) makalesinden uyarlandı.

Çalışma iki aşamada yürütüldü: önce kendi ürettiğimiz sentetik veriyle model ve metodoloji geliştirildi, ardından gerçek saha verisine geçildi. Son aşamada model ONNX biçiminde teslim edildi ve ekibin test altyapısında saha koşullarında denendi.

2. Yapılan iş

Aşama 1 — sentetik veri. Kendi ürettiğimiz sentetik spektrogramlarla geliştirilen model, dört katlı ve kaynak-gruplu çapraz doğrulamada macro-F1 0.622 ± 0.166 elde etti. Bu değer düşük görünmekle birlikte dürüsttür: yaklaşık 960 spektrogram yalnızca 19 bağımsız ses kaydından türetilmişti ve rastgele bölme yapılsaydı skor yapay olarak %99 seviyesine çıkardı. Tavamı belirleyen model değil veriydi. Bu aşamadan mimari, ön işleme disiplini, sızıntı testleri ve metodoloji kalıcı olarak taşındı; ağırlıklar taşınmadı, çünkü aktarımın zararlı olduğu sonradan ölçüldü.

Aşama 2 — gerçek saha verisi. Veri seti 373.908 pencere ve 14.490 benzersiz oturum içermektedir; bölmeler dosya, oturum ve tarih düzeyinde çakışmasız gelmektedir. Taban çizgisi olarak elle çıkarılmış 26 özellik üzerinde eğitilen doğrusal bir sınıflandırıcı kullanıldı ve macro-F1 0.771 ölçüldü.

Beş eğitim koşusu yapıldı; hiçbir test setine bakılarak seçilmedi (Tablo 1). En iyi sonuç, evrişimli omurgayı aynen koruyup yalnızca havuzlama başını zamansal bir dizi modeliyle değiştiren CNN-BiLSTM mimarisinden geldi: **macro-F1 0.9390**. Taban çizgisi 0.168 puan farkla aşıldı.

Table 1: Beş koşunun test seti sonuçları. Hiçbir konfigürasyon test setine bakılarak seçilmemiştir.

#	mimari	girdi	başlangıç / rejim	test macro-F1
4	CNN-BiLSTM	viridis	sıfırdan / yeni	0.9390
1	2D-CNN + SK	viridis	sıfırdan / eski	0.8843
3	2D-CNN + SK	gri	sıfırdan / eski	0.8737
5	2D-CNN + SK	gri	sıfırdan / yeni	0.8704
2	2D-CNN + SK	viridis	aktarım / eski	0.8658
—	taban çizgisi (doğrusal, 26 özellik)	—	—	0.771

Kazancın kaynağı fark-farkı hesabıyla atfedildi: kazancın tamamı *mimariden* gelmektedir (+0.058). Eğitim rejimi değişikliğinin katkısı ölçüldü ve sıfır çıktı (−0.003); sentetik ön-eğitim aktarımı ise

zararlı bulundu (-0.019). Kazanç tam da hedeflenen çiftte toplandı — `cutting` $+0.090$, `climbing` $+0.066$, `noise` $+0.008$ — ve iki saldırı sınıfı arasındaki karışıklık yarıya indi.

Teslim — ONNX. Sorumlunun isteği modelin ham sinyal almasıydı. Bu nedenle ön işlemin tamamı hesap grafiğinin içine gömüldü: pencere-içi normalizasyon, STFT, dB dönüşümü, renklendirme, ölçekleme ve ImageNet normalizasyonu. Dosyanın dış arayüzü şöyledir:

yön	ad	şekil	açıklama
girdi	sinyal	(batch, 15000)	ham genlik, P alanı, 7.5 s @ 2000 Hz
çıktı	logit	(batch, 3)	<code>cutting</code> · <code>climbing</code> · <code>noise</code>
çıktı	bosluk_orani	(batch,)	pencere geçerlilik ölçütü

opset 13, IR sürümü 7. Dört ONNX engeli çözüldü: `aten::fft_rfft`, `aten::median`, uyarlanabilir havuzlama ve `antialias`. Ön işlemin gömülü olması, ekibin mevcut kodunda tespit edilen dört tutarsızlık riskini (ölçek katsayısı, pencere boyutu, P/S bileşeni, sessiz pencere filtresi) tamamen ortadan kaldırmaktadır; çağırın tarafın herhangi bir ön işleme yazmasına gerek yoktur.

3. Saha testi ve çözülen sorun

Model ekibin test altyapısına yüklendiğinde ortaya çıkan tablo, test setindeki 0.9390 değeriyle geliyordu: olay olmayan kanallarda yaygın ve kesintisiz yanlış alarm görülüyordu. Teşhis dört adımda tamamlandı.

(i) noise sınıfı “boşluk” anlamına gelmiyor. Veri setimizde `noise`, etiketlenmiş bir olay türüdür (ortam gürültüsü, araç). Boş pencereler eğitimden *silinmişti* (%23) ve `noise` olarak etiketlenmemişti. Sonuç olarak modelin “hiçbir şey yok” diyebileceği bir çıkışı yoktu; her pencerede üç sınıftan birini seçmek zorundaydı. Ölçüldü: boş pencerelerin **%99.8**’inde bir saldırı sınıfı seçmektedir.

(ii) Sebep mimari değil, girdi temsili. İlk teşhis BiLSTM’in zamansal havuzlamasını suçladı; dört koşu birlikte ölçülünce bu çürüdü (Tablo 2). İki viridis modeli de başarısız, iki gri modeli de başarılıdır; mimari ve eğitim rejimi bu davranışla ilgisiz çıkmıştır. Viridis bırakıldı — zaten tek gerekçesi sentetik modelle temsil paritesiydi ve o aktarım daha önce çürütülmüştü.

Table 2: Boş pencerelerde yanlış alarm oranı. Belirleyici değişken mimari değil, girdi temsidir.

koşu	mimari	girdi temsili	boş pencerede yanlış alarm
1	2D-CNN + SK	viridis	%99.7
4	CNN-BiLSTM	viridis	%99.7
3	2D-CNN + SK	gri	%0.0
5	2D-CNN + SK	gri	%0.1

(iii) Boşluk ölçütünün iki kusuru. Modele “bu pencerede sinyal var mı” sorusunu soran ikinci bir çıktı zaten mevcuttu, ancak sahada tetiklenmiyordu. İki kusur bulundu. Birincisi, sinyal tamamen sabit olduğunda (ölü kanal) hesap sıfıra bölünmeye düşüyor ve `numpy` sürümü 1.0 (boş), ONNX sürümü 0.0 (dolu) döndürüyordu; tek satırlık bir tutarsızlık. İkincisi ve daha önemlisi, ölçüt yalnızca 500 Hz *üstündeki* enerji payına bakıyordu. Ölü ya da zayıf bir kanalda yüksek frekans bileşeni bulunmaz; yalnızca yavaş bir taban kayması vardır. Bu durumda oran düşük çıkmakta ve pencere “dolu” sayılmaktaydı — yani ölçüt tam tersini ölçüyordu.

(iv) **Ham veri formatının çözülmesi.** Sorunu ölçmek için kaydın 201 kanalının tamamı gerekiyordu; elimizdeki `.hdf5` kopyaları olay çevresine kırılmış durumdaydı (6–14 kanal). Ham `.bin` formatı tersine mühendislikle çözüldü ve kırılmış kopyayla birebir doğrulandı (maksimum fark 0): 16.384 baytlık başlık, ardından `uint16` little-endian, zaman-öncelikli (*örnek, kanal*) düzeni. Bu sayede yanlış alarmların yalnızca **5 kanalda** toplandığı görüldü; 201 kanalın 153’ü hiç alarm üretmiyordu.

Çözüm. 100 Hz *altındaki* enerji payı ikinci bir ölçüt olarak eklendi ve bastırma doğrudan hesap grafiğine gömüldü. Gerçek olayların %95’ini koruyan eşikte artefakt pencerelerinin **%92.5**’i susturulmaktadır; eski ölçüt aynı testte %20.0’da kalıyordu. Çözüm yeniden eğitim gerektirmedi; çıktı şekli değişmediği için çağırın tarafta da hiçbir değişiklik gerekmemektedir.

4. Teslim edilen model ve saha başarımı

Teslim edilen model `sk_gri_kosu3_v2.onnx` dosyasıdır: koşu 3 (2D-CNN + SK, gri girdi temsili), iki ölçütlü boşluk bastırması, opset 13, IR 7. Saha ölçümü 7 dosya, 201 kanal ve 8.040 pencere üzerinde yapılmıştır (Tablo 3).

Table 3: Saha ölçümü, eşik 0.90. Bastırmaz CNN-BiLSTM sahada kullanılamaz durumdadır; bastırma onu 40 kat toparlamaktadır.

model	bastırma	kaçırma	yanlış alarm
2D-CNN + SK, gri	yok	%39.3	%3.2
2D-CNN + SK, gri	var	%40.8	%0.5
CNN-BiLSTM	yok	%29.8	%55.5
CNN-BiLSTM	var	%31.2	%1.4

Model seçimi neden BiLSTM olmadı. CNN-BiLSTM kaçırmada 9.6 puan daha iyidir, ancak yanlış alarmı üç katıdır. İlk bakışta bu takas lehte görünmektedir; *ancak iki yüzde, uygulandıkları popülasyonlar farklı büyüklükteyse doğrudan karşılaştırılmaz*. Ölçümde 272 GT-içi pencereye karşılık 7.768 GT-dışı pencere bulunmaktadır (1:28.5). Her 100 olay penceresine yaklaşık 2.856 olay-dışı pencere düşmektedir:

model (eşik 0.90)	100 olayda tespit	yanlış alarm sayısı
2D-CNN + SK, gri, bastırmalı	59.2	14.3
CNN-BiLSTM, bastırmalı	68.8	40.0
fark	+9.6	+25.7

Yani her ek tespit için 2.7 ek yanlış alarm üretilmektedir. Operatörün karşılaştığı sayı budur ve bu nedenle SK modeli tercih edilmiştir.

Önerilen çalışma noktası. Eşik eğrisi çıkarılmıştır. 0.90’ın üstündeki her değer saf kayıptır: yanlış alarm zaten dip seviyededir ve yalnızca kaçırma artmaktadır. Teslim modeli için önerilen nokta **eşik 0.75**’tir — kaçırma %35.7, yanlış alarm %0.8. Daha agresif bir nokta gerekirse 0.50 eşiği %27.2 kaçırma ve %2.0 yanlış alarm vermektedir.

5. Nereye kadar gelindi

Tamamlananlar

- Taban çizgisi 0.168 puan farkla aşıldı (0.771 → 0.9390).

- Kazancın kaynağı ölçülerek atfedildi; üç hipotez çürütüldü.
- Ham sinyal alan, ön işlemesi gömülü ONNX teslimi yapıldı.
- Saha yanlış alarm sorunu teşhis edildi ve yeniden eğitim olmadan çözüldü (%55.5 → %1.4 CNN-BiLSTM’de, %3.2 → %0.5 teslim modelinde).
- Ham veri formatı çözüldü; 201 kanalın tamamı okunabilir hâle geldi.
- Üç kalıcı kural belgelendi: alfabetik sınıf sırası, gri girdi temsili, ONNX’in her zaman ham sinyal alması.

Açık kalanlar

- **Kaçırma %35.7** (teslim modeli, eşik 0.75) — asıl kalan sorun.
- **Koşu 7 (CNN-BiLSTM + gri)** hiç koşturulamadı; kod hazır olmasına rağmen GPU gün boyunca başka bir işlem tarafından dolu tutuldu.
- Kaçırmanın yapısal analizi koşu 4 ile yapıldı, teslim modeliyle tekrarlanmalıdır.
- `.sdf` dosyalarında `duration` × `prf` çarpımı ile diskteki örnek sayısı tam iki kat uyuşmamaktadır; gerçek örnekleme hızının 4000 Hz olup olmadığı teyit edilmelidir.
- Eğitim etiketleri 224 kanala kadar yayılabilmektedir; bazı etiket gruplarında pencerelerin %92–100’ü boştur.

6. Kaçırma — devredilen problem

Bu, projenin devredilen ana problemidir. Teslim modelinde kaçırma oranı eşik 0.75’te %35.7, eşik 0.90’da %40.8’dir.

Doğrulanmış gözlemler. Kaçırma, olayın kanal kenarlarında merkezin yaklaşık üç katıdır (%37.5 ve %31.7 kenarda, %11.7 merkezde). Kaçırılan pencereler düşük frekans baskındır: 100 Hz altındaki enerji payı 0.802 iken, yakalanan pencerelerde 0.587’dir. Bu, zayıf ve uzak olayların beklenen imzasıdır — yüksek frekanslar fiber boyunca ve ortamda önce sönmüştür. Ayrıca geniş olaylar daha çok kaçırılmaktadır (%15, %35 ve %54; sırasıyla 3, 4 ve 7 kanallı olaylarda).

Çürütülen iki hipotez. Birincisi, “ground truth bir zaman aralığı işaretliyor ve o aralıkta hareketin durduğu anlar var, dolayısıyla kaçırma abartılı görünüyor” denmişti. Ölçüldü: kaçırılan pencerelerin yalnızca %17.1’i spektral olarak boştur; düzeltilmiş kaçırma %30.7 yerine %25.5’tir. Kaçırmalar gerçektir. İkincisi, “eğitimde zayıf pencereleri eleme olabiliyoruz” denmişti. Elenen pencerelerin ölçütleri incelendiğinde bunların zayıf olay değil, saf gürültü olduğu görüldü (medyan mutlak sapma 0.45’e karşılık kalanların 27.26’sı; 100 Hz altı enerji payı 0.100’e karşılık kaçırılanların 0.802’si). Filtre doğru çalışmıştır.

Bu ne anlama geliyor. İki hipotezin de çürütülmesi problemi yeniden konumlandırmaktadır: model bu pencereleri *görmüştür*, buna rağmen tanımamaktadır. Dolayısıyla sorun veri eksikliği değil, modelin temsil ve ayırt etme kapasitesidir.

Ve bir gerilim. Boşluk bastırma ölçütümüz, kaçırılan gerçek olaylarla aynı ekseninde çalışmaktadır: yakalanan olay 0.587, kaçırılan olay 0.802, artefakt kanal 0.956. Eşiği düşürüp daha çok artefakt yakalamak, zayıf gerçek olayları da susturacaktır. Yanlış alarm ile kaçırma, aynı fiziksel büyüklüğün iki ucudur ve bu, ilerideki her çözümün hesaba katması gereken bir kısıttır.

7. Bundan sonra — yol haritası

7.1 Kısa vade (kod hazır, yalnızca koşturulacak).

1. **Koşu 7: CNN-BiLSTM + gri girdi.** Bu kombinasyon hiç denenmedi ve en yüksek getirili koşudur. CNN-BiLSTM viridis olduğu için elendi: kaçırma 9.6 puan daha iyi olmasına rağmen yanlış alarmı SK'nin üç katıdır ve bastırma viridis'in zararını tamamen almamaktadır. Gri bir CNN-BiLSTM, mimarının tespit üstünlüğünü gri temsili boşluk sağlamlığıyla birleştirebilir. Kod hazırdır; yaklaşık 100 dakika ve boş bir GPU gerektirir.
2. **Kaçırma analizini teslim modeliyle tekrarla.** Yapısal bulgular koşu 4 ile ölçüldü. Kaçırmanın yapısı bir veri ve fizik özelliği olduğu için mimariden bağımsız olması beklenir, ancak bu varsayım ölçülmemiştir. CPU üzerinde birkaç dakika sürer.
3. **Çalışma noktasını sorumluyla birlikte belirle.** Eşik eğrisi çıkarılmıştır; 0.90'ın üstü saf kayıptır ve 0.75 iki ekseninde de daha iyidir.
4. **.sdf örnekleme hızı sorusunu teyit ettir ve teslim paketini (.pt) güncel koşuya taşı.**

7.2 Orta vade — sorunun yeni konumuna göre. Kaçırma artık bir veri problemi değil, model temsili problemi olarak görünmektedir. Bu, daha önce değerlendirilip ertelenen yaklaşımları yeniden anlamlı kılmaktadır.

Kosinüs tabanlı sınıflandırma katmanı (marjinsiz). Mevcut son katman düz bir doğrusal katmandır ve ürettiği logit sınırsız bir iç çarpımdır; yani “model ne kadar emin” sorusunun ölçeklenebilir bir cevabı yoktur. Özellik vektörü ile sınıf ağırlıkları normalize edilip logit $[-1, 1]$ aralığında bir kosinüs benzerliğine çevrilirse skor “bu örnek sınıf prototipine ne kadar yakın” biçiminde okunabilir hâle gelir ve sınırdaki zayıf örnekler için karar eşiği anlam kazanır. Ucuz, riski düşük ve ilk denenmesi gereken adımdır.

Açısal marjın yöntemleri (ArcFace, CosFace). Kosinüs katmanının üzerine bir açısal marjın eklenerek sınıflar hiperküre üzerinde sıkı kümeler hâline getirilir ve aralarındaki boşluk büyütülür. Sınırdaki zayıf örnekleri ayırt etmek tam da bu yöntemlerin iddia ettiği şeydir ve projenin kalan sorunu tam olarak budur. Bir çekince vardır: normalizasyon özellik normunu atmaktadır ve dağılım-dışı örnek tespitinde norm başlı başına güçlü bir sinyaldir. Doğru kullanım, kosinüsü sınıflandırma için kullanıp reddetme skorunu ayrı tutmaktır. Üç sınıflı bir problemde ölçek ve marjın parametrelerinin ayarı hassastır; deneme gerektirir.

Segmentasyon çerçevesi. Problemi pencere pencere sınıflandırma yerine kanal $\times$ zaman ızgarasında olay maskesi tahmin etmeye çevirmek mümkündür. Bu durumda model komşuluk bilgisini görür ve gerçek olayların bitişik bloklar oluşturduğunu kendisi öğrenir; tek kanallı sahte sütunlar kendiliğinden elenir. Etiket verisi buna uygundur, ancak mimari ve veri hattı değişikliği gerektiren büyük bir iştir.

Denenmemesi önerilenler. Dice kaybı, piksel bazlı segmentasyonda dengesizliği ele almak için tasarlanmıştır ve bu problem tipine uygun değildir. Genel maliyet duyarlı ağırlıklandırma ise karar sınırını yalnızca mevcut sınıflar arasında kaydırır, “hiçbiri” seçeneği yaratmaz; etkisi büyük ölçüde eşik değiştirmekle aynıdır ve eğriyi kaydırmak yerine üzerinde kaydırma riski taşır.

7.3 Veri tarafı.

- **Etiket kalitesi** incelenmelidir. Etiketlerin 224 kanala kadar yayılması ve bazı gruplarda pencerelerin %92–100'ünün boş olması, eğitim sinyalini seyreltiyor olabilir.
- **.sdf örnekleme hızı** netleştirilmelidir. Uyuşmazlık doğruysa, o dosyalarla yapılan tüm saha testleri geçersizdir.
- **Değerlendirme seti küresyonludur.** Doğrulama ve test bölmelerinde boş pencere oranı %0.1 iken eğitimde %23'tür; mevcut test seti saha koşullarını temsil etmemektedir. Gerçekçi bir değerlendirme seti kurulması, ilerideki her ölçümün güvenilirliğini artıracaktır.

8. Metodolojik notlar

Bu projede en değerli bulguların tamamı ölçümden çıkmıştır ve çoğu sezgiyi çürütmüştür (Tablo 4). Bu, projenin en aktarılabilir çıktısıdır: bir tahmin ne kadar makul görünürse görünsün, ölçülmeden karar verilmemiştir.

Table 4: Tahminler ve ölçümler. Altı tahminin altısı da çürütülmüştür.

tahmin	ölçüm
Sentetik ön-eğitim yardım eder	etmedi, -0.019
Viridis zarar verir	test setinde vermedi ($+0.011$), sahada felaket
Rejim düzeltmesi skoru artırır	artırmadı, -0.003
BiLSTM’in zaman havuzlaması suçlu	değil, sebep girdi temsili
Ground truth sessiz anları kapsıyor	kaçırmanın yalnızca %17’si
Zayıf pencereleri elemeşiz	elenenler saf gürültü

Çalışma boyunca izlenen ilkeler şunlardır: eğitim ve çıkarım aynı fonksiyonu çağırır (tek kod yolu); ölçmeden karar verilmez; tahmin ölçümle geliştiğinde ölçüm kazanır ve bu yazılır; test setine bakarak hiperparametre seçilmez; kararlar sohbe değil dosyalara yazılır. Tekrarlanmaması gereken hatalar ayrı bir bölümde toplanmıştır — aralarında “asla başarısız olamayan doğrulama yazmak”, “yanlış popülasyonda ölçüp *işe yaramıyor* demek” ve “açılamayan dosyayı yok saymak” gibi bu projede fiilen yaşanmış on bir madde bulunmaktadır.

Son olarak, bu raporda kaydedilen bir yorum hatası da aktarılmaya değerdir: model seçimi sırasında iki yüzde (kaçırma ve yanlış alarm) doğrudan yan yana konularak takas yapılmış, ancak bu iki oranın 28 kat farklı büyüklükteki popülasyonlara uygulandığı gözden kaçmıştı. Ölçüm doğrudu; yorum yanlıştı. Taban oranı hesaba katılınca model tercihi tersine döndü.